iscte
SINTRA
TECNOLOGIAS DIGITAIS
ECONOMIA E SOCIEDADE

Relatório do Projeto 2

Ilie Cosmin Iftime, nº 112779
Inês Rodrigues da Cruz, nº 123557
Sofia Feliciano Quintino, nº123554

Algoritmos Avançados de Procura
Docente: Ricardo Miranda

Licenciatura Tecnologias Digitais e Inteligência Artificial

2º Semestre 2025/2026

Índice

Resumo 3
Introdução 1
Descrição das abordagens implementadas 3
Problema 1- N-Rainhas 3
Formulação do problema 3
CSP com Forward Checking e AC-3 4
Algoritmo Genético 4
Tabu Search 4
Problema 2- Problema do Caixeiro Viajante (TSP) 5
Formulação do problema 5
Particle Swarm Optimization 5
Ant Colony Optimization 5
Problema 3- Problema de Veículos com Capacidade (CVRP) 6
Formulação do problema 6
Representação Giant-Tour + Split 6
Algoritmo Genético 6
Justificação das decisões de modelação e dos parâmetros utilizados 7
Decisões de modelação 7
Escolha dos parâmetros 7
Reprodutibilidade experimental 8
Apresentação e análise dos resultados experimentais 8
Problema 1- N-Rainhas 9
Comparação global dos algoritmos 9
Análise de escalabilidade 10
Análise estatística 10
Discussão dos resultados 11
Problema 2- TSP 12
Comparação entre PSO e ACO 12
Qualidade das soluções obtidas 12
Influência dos parâmetros 13
Análise estatística 14
Discussão dos resultados 14
Problema 3- CVRP 15
Qualidade das soluções obtidas 15
Análise das rotas geradas 16

Discussão dos resultados 17
Comparação entre o Projeto 1 e o Projeto 2 17
Discussão crítica dos resultados 18
Influência da estrutura do problema 18
Comparação entre paradigmas 19
Limitações do estudo 19
Possíveis melhorias e trabalho futuro 20
Conclusões 20
Referências Bibliográficas 21

Figura 1- Comparação dos algoritmos aplicados ao problema das N-Rainhas. 10
Figura 2- Curvas de convergência do PSO e do ACO para a instância TSP com 20 cidades.
..... 12
Figura 3- Comparação da qualidade das soluções obtidas pelo PSO e pelo ACO para diferentes dimensões do Problema do Caixeiro Viajante. .....
13 Figura 4- Análise da influência dos parâmetros β e ρ no desempenho do algoritmo ACO para a instância TSP com 50 cidades.....
14 Figura 5- Exemplo de solução obtida para a instância CVRP com 50 clientes.
17

Tabela 1- Resultados médios obtidos para o problema das N-Rainhas. .....
9

Resumo

O presente trabalho teve como objetivo estudar e comparar diferentes paradigmas de procura e otimização através da resolução de três problemas clássicos da Inteligência Artificial e da otimização combinatória: o problema das N-Rainhas, o Problema do Caixeiro Viajante (*Travelling Salesman Problem* – TSP) e o Problema de Veículos com Capacidade (*Capacitated Vehicle Routing Problem* – CVRP).

No problema das N-Rainhas foram implementadas e comparadas abordagens de satisfação de restrições (*Constraint Satisfaction Problems* – CSP), através dos algoritmos *Forward Checking* e *AC-3*, um algoritmo genético e o algoritmo *Tabu Search* desenvolvido no Projeto 1. Para o TSP foram implementadas duas metaheurísticas inspiradas em sistemas naturais: *Particle Swarm Optimization* (PSO) e *Ant Colony Optimization* (ACO). No CVRP foi desenvolvido um algoritmo genético baseado na estratégia *Giant-Tour + Split*.

Todos os algoritmos foram implementados de raiz, sem recurso a bibliotecas especializadas de otimização, sendo as experiências realizadas de forma reprodutível através de uma semente aleatória fixa e de um conjunto de métricas quantitativas adequadas a cada problema.

Os resultados obtidos demonstraram que os métodos CSP constituem a abordagem mais eficaz para o problema das N-Rainhas, explorando de forma eficiente a estrutura das restrições. No TSP, o *Ant Colony Optimization* produziu soluções de melhor qualidade e maior estabilidade do que o *Particle Swarm Optimization*. No CVRP, o algoritmo genético revelou-se capaz de gerar soluções viáveis e eficientes, respeitando integralmente as restrições de capacidade.

Conclui-se que não existe um algoritmo universalmente superior para todos os problemas. O desempenho depende fortemente da natureza do problema e da capacidade de cada paradigma para explorar a estrutura e a informação disponível durante o processo de procura.

Introdução

Os problemas de procura e de otimização combinatória ocupam um lugar central na Inteligência Artificial, tanto pela sua relevância prática como pela diversidade de técnicas desenvolvidas para os resolver. Muitas aplicações reais, como o planeamento, a logística, a escalabilidade de tarefas ou a gestão de redes de transporte, podem ser formuladas como problemas em que é necessário encontrar uma solução ótima ou próxima do ótimo num espaço de procura extremamente vasto. Em muitos destes casos, pertencentes à classe dos problemas NP-difíceis, a obtenção da solução ótima por métodos exatos tornase rapidamente impraticável à medida que a dimensão das instâncias aumenta,

justificando o recurso a algoritmos heurísticos, metaheurísticas e técnicas de satisfação de restrições.

Um dos principais desafios nesta área consiste em compreender de que forma as características estruturais de cada problema influenciam o desempenho dos diferentes paradigmas algorítmicos. Enquanto algumas abordagens exploram explicitamente a estrutura do problema através de mecanismos de propagação e poda, outras recorrem a estratégias evolucionárias ou a comportamentos inspirados em sistemas naturais para explorar o espaço de soluções. Comparar estas abordagens em domínios distintos permite identificar as condições em que cada uma revela maior eficácia e compreender os compromissos existentes entre qualidade da solução, tempo de execução, robustez e escalabilidade.

O presente trabalho dá continuidade ao Projeto 1 da unidade curricular, reutilizando o problema das N-Rainhas como domínio comum de comparação. No projeto anterior este problema foi abordado através de algoritmos de procura local, tendo o Tabu Search demonstrado um desempenho superior aos restantes métodos estudados. Neste projeto, o mesmo problema é reformulado segundo novos paradigmas, recorrendo a técnicas de satisfação de restrições e a algoritmos genéticos. Esta reutilização permite comparar diretamente diferentes abordagens sobre o mesmo problema e analisar o impacto da estrutura disponível na eficiência da procura.

Para além do problema das N-Rainhas, o trabalho inclui ainda o Problema do Caixeiro Viajante (*Travelling Salesman Problem* – TSP), resolvido através de *Particle Swarm Optimization* e *Ant Colony Optimization*, e o Problema de Veículos com Capacidade (*Capacitated Vehicle Routing Problem* – CVRP), resolvido através de um algoritmo genético baseado na estratégia *Giant-Tour + Split*. Estes problemas complementam o estudo realizado, permitindo analisar diferentes paradigmas de otimização em contextos de complexidade crescente e com aplicações diretas em logística e distribuição.

Todos os algoritmos foram implementados de raiz, sem recurso a bibliotecas especializadas de otimização, privilegiando-se a compreensão dos mecanismos fundamentais de cada abordagem. As experiências foram conduzidas de forma reprodutível, recorrendo a uma semente aleatória fixa e a métricas quantitativas que permitem comparar objetivamente o desempenho dos algoritmos em diferentes instâncias e dimensões.

O objetivo central deste trabalho consiste em estudar a relação entre a estrutura dos problemas e o desempenho dos algoritmos utilizados, identificando as situações em que cada paradigma se revela mais adequado e retirando conclusões fundamentadas sobre as suas vantagens, limitações e potencial de aplicação.

Descrição das abordagens implementadas

Este projeto aborda três problemas clássicos de procura e otimização combinatória através de diferentes paradigmas algorítmicos. O primeiro problema, o das N-Rainhas, foi utilizado para comparar métodos de satisfação de restrições, algoritmos evolucionários e procura local. O segundo problema corresponde ao Problema do Caixeiro Viajante (*Travelling Salesman Problem* – TSP), onde foram estudadas duas metaheurísticas inspiradas em sistemas naturais. Por fim, o terceiro problema consiste no Problema de Veículos com Capacidade (*Capacitated Vehicle Routing Problem* – CVRP), resolvido através de um algoritmo genético especializado.

Em todos os casos, os algoritmos foram implementados de raiz na biblioteca utils_algoritmos.py, sem recurso a bibliotecas externas que resolvessem diretamente os problemas considerados. Esta opção permitiu controlar integralmente os mecanismos de representação, avaliação e procura utilizados em cada abordagem.

As secções seguintes descrevem a formulação de cada problema e os algoritmos implementados para a sua resolução.

Problema 1- N-Rainhas

O problema das N-Rainhas consiste em posicionar N rainhas num tabuleiro de dimensão N × N de forma que nenhuma rainha ataque outra. Para tal, não podem existir duas rainhas na mesma linha, coluna ou diagonal. Este problema constitui um dos exemplos clássicos da Inteligência Artificial, sendo frequentemente utilizado para avaliar algoritmos de procura, satisfação de restrições e otimização.

Neste trabalho, o problema foi abordado através de três paradigmas distintos: satisfação de restrições (*Constraint Satisfaction Problems* – CSP), algoritmos genéticos e procura local. A utilização do mesmo domínio permitiu comparar abordagens que exploram a estrutura do problema de formas substancialmente diferentes.

Formulação do problema

Nas abordagens baseadas em procura local e algoritmos genéticos, o tabuleiro é representado através de um vetor de dimensão N. Cada posição do vetor corresponde a uma coluna e o valor armazenado indica a linha ocupada pela respetiva rainha. Esta representação elimina automaticamente os conflitos de coluna, reduzindo o problema à deteção de conflitos de linha e de diagonal.

A qualidade de uma solução é determinada pelo número de pares de rainhas em conflito. Uma configuração é considerada solução quando não existem conflitos entre quaisquer pares de rainhas.

CSP com Forward Checking e AC-3

Na formulação como problema de satisfação de restrições, cada coluna do tabuleiro é modelada como uma variável e o respetivo domínio corresponde ao conjunto das linhas possíveis. As restrições garantem que duas rainhas não podem ocupar simultaneamente a mesma linha nem a mesma diagonal.

A procura é realizada através de retrocesso (*backtracking*) e utiliza a heurística *Minimum Remaining Values* (MRV), que seleciona prioritariamente a variável com menor número de valores válidos disponíveis.

Foram implementados dois mecanismos de propagação de restrições. O *Forward Checking* elimina imediatamente dos domínios futuros todos os valores incompatíveis com a atribuição corrente, permitindo detetar precocemente situações sem solução. O algoritmo *AC-3* reforça este processo através da propagação da consistência de arcos, removendo iterativamente valores que deixem de possuir suporte nos domínios das variáveis relacionadas.

Algoritmo Genético

Na abordagem evolucionária, cada cromossoma é representado por uma permutação dos valores entre 0 e N−1. Esta representação garante automaticamente a inexistência de conflitos de linha e de coluna, permanecendo apenas os conflitos diagonais como objetivo da otimização.

A aptidão de cada indivíduo é calculada a partir do número de conflitos existentes, atribuindo valores mais elevados às soluções que apresentam menos ataques entre rainhas. A seleção dos progenitores é realizada por torneio, enquanto o cruzamento utiliza o operador *Order Crossover* (OX), adequado a representações por permutação. A diversidade genética é introduzida através de mutações por troca de posições, sendo ainda utilizado elitismo para preservar os melhores indivíduos entre gerações.

Tabu Search

Como termo de comparação foi utilizada a implementação do *Tabu Search* desenvolvida no Projeto 1. Este algoritmo pertence à família dos métodos de procura local e baseia-se na exploração iterativa da vizinhança de uma solução corrente.

Para evitar ciclos e ultrapassar ótimos locais, o algoritmo mantém uma lista tabu que impede temporariamente a repetição de movimentos recentemente efetuados. Em cada iteração é selecionado o melhor movimento admissível, mesmo que não produza uma melhoria imediata da solução. Esta estratégia permite explorar regiões mais amplas do espaço de procura e foi responsável pelos elevados níveis de sucesso observados no projeto anterior.

A inclusão do *Tabu Search* neste trabalho permite comparar diretamente três paradigmas distintos — satisfação de restrições, algoritmos evolucionários e

procura local — sobre o mesmo problema e nas mesmas dimensões experimentais.

Problema 2- Problema do Caixeiro Viajante (TSP)

O Problema do Caixeiro Viajante (*Travelling Salesman Problem* – TSP) consiste em determinar o percurso de menor custo que visita cada cidade exatamente uma vez e regressa ao ponto de partida. Trata-se de um dos problemas mais estudados da otimização combinatória devido à sua dificuldade computacional e às suas numerosas aplicações em logística, planeamento de rotas e distribuição.

Neste trabalho, o problema foi abordado através de duas metaheurísticas inspiradas em sistemas naturais: o *Particle Swarm Optimization* (PSO) e o *Ant Colony Optimization* (ACO).

Formulação do problema

Cada instância é constituída por um conjunto de cidades representadas por coordenadas bidimensionais. A partir dessas coordenadas é construída uma matriz de distâncias euclidianas, utilizada para avaliar a qualidade das soluções.

Uma solução corresponde a uma permutação das cidades, representando a ordem pela qual estas são visitadas. O custo de uma rota é dado pela soma das distâncias percorridas ao longo de todo o percurso, incluindo o regresso à cidade inicial. O objetivo consiste em minimizar essa distância total.

Particle Swarm Optimization

O *Particle Swarm Optimization* foi originalmente concebido para espaços contínuos, tendo sido adaptado neste trabalho ao domínio das permutações.

Cada partícula representa uma rota completa e a velocidade é modelada como uma sequência ordenada de trocas (*swaps*). A atualização da velocidade combina três componentes: a inércia do movimento anterior, a atração pela melhor solução individual encontrada pela partícula e a atração pela melhor solução encontrada pelo enxame.

A aplicação destas sequências de trocas gera novas rotas, permitindo que o conjunto de partículas explore progressivamente o espaço de soluções.

Ant Colony Optimization

O *Ant Colony Optimization* é inspirado no comportamento coletivo das colónias de formigas na procura de caminhos entre o ninho e fontes de alimento. No contexto do TSP, cada formiga constrói uma rota de forma incremental, selecionando sucessivamente a próxima cidade a visitar.

A escolha depende da combinação entre a quantidade de feromona acumulada em cada arco e uma informação heurística baseada na distância entre cidades. Após cada iteração, as feromonas sofrem evaporação e são reforçadas pelas

melhores rotas encontradas, tornando progressivamente mais atrativos os percursos de menor custo.

A combinação entre aprendizagem coletiva, informação heurística e reforço das melhores soluções faz do ACO uma das metaheurísticas mais utilizadas para problemas de roteamento e otimização combinatória.

Problema 3- Problema de Veículos com Capacidade (CVRP)

O Problema de Veículos com Capacidade (*Capacitated Vehicle Routing Problem* – CVRP) é uma generalização do Problema do Caixeiro Viajante em que um conjunto de clientes com procuras conhecidas deve ser servido a partir de um depósito central por veículos com capacidade limitada. O objetivo consiste em minimizar a distância total percorrida, garantindo simultaneamente o cumprimento das restrições de capacidade.

Neste trabalho, o problema foi resolvido através de um algoritmo genético baseado numa representação especializada para problemas de roteamento.

Formulação do problema

Cada instância é constituída por um depósito, um conjunto de clientes com localização conhecida e uma procura associada a cada cliente. Os veículos partem do depósito, visitam um conjunto de clientes e regressam ao ponto de origem.

Uma solução é composta por várias rotas, devendo cada cliente ser visitado exatamente uma vez. Para além da minimização da distância total percorrida, é necessário garantir que a soma das procuras dos clientes servidos por cada veículo não excede a capacidade disponível.

Representação Giant-Tour + Split

A representação adotada baseia-se na estratégia *Giant-Tour* + *Split*. Cada cromossoma corresponde a uma permutação de todos os clientes, sem qualquer separação explícita em rotas.

Posteriormente, um operador *Split* percorre a sequência de clientes e constrói automaticamente as rotas. Sempre que a inclusão de um novo cliente faria ultrapassar a capacidade do veículo, é iniciada uma nova rota. Esta abordagem permite gerar soluções viáveis de forma simples e eficiente, reduzindo a necessidade de mecanismos de reparação ou penalização.

Algoritmo Genético

O algoritmo genético utiliza uma população de soluções representadas pela sequência de clientes. A evolução da população é realizada através de seleção por torneio, cruzamento *Order Crossover* (OX) e operadores de mutação baseados em trocas e inversões de segmentos.

A qualidade de cada indivíduo é avaliada após a aplicação do operador *Split*, calculando-se o custo total das rotas geradas. Esta combinação entre representação por permutação e construção automática de rotas permite explorar eficientemente o espaço de soluções, mantendo simultaneamente o respeito pelas restrições de capacidade impostas pelo problema.

Justificação das decisões de modelação e dos parâmetros utilizados

As decisões de modelação adotadas ao longo deste projeto tiveram como principal objetivo garantir representações adequadas à natureza de cada problema, reduzindo a complexidade da procura e permitindo uma comparação justa entre diferentes paradigmas algorítmicos. Paralelamente, a escolha dos parâmetros procurou equilibrar qualidade das soluções, tempo de execução e reprodutibilidade experimental.

Decisões de modelação

No problema das N-Rainhas foram utilizadas duas representações distintas. Na formulação CSP, cada coluna do tabuleiro foi modelada como uma variável e cada linha como um valor possível do respetivo domínio. Esta representação permite explorar diretamente a estrutura das restrições através de mecanismos de propagação. Nas abordagens baseadas em procura local e algoritmos genéticos foi utilizada uma representação por permutação, em que cada posição representa uma coluna e cada valor a linha ocupada pela respetiva rainha. Esta escolha elimina automaticamente os conflitos de coluna e reduz significativamente o espaço de procura.

No Problema do Caixeiro Viajante, as soluções foram igualmente representadas por permutações das cidades. Esta representação é a mais natural para problemas de roteamento, garantindo que cada cidade é visitada exatamente uma vez. A adaptação do PSO a este contexto exigiu a representação da velocidade através de sequências de trocas (*swaps*), permitindo preservar a validade das rotas durante o processo de otimização.

No Problema de Veículos com Capacidade foi adotada a estratégia *Giant-Tour + Split*. Em vez de codificar explicitamente as rotas dos veículos, cada cromossoma representa apenas uma sequência de clientes. A separação em rotas é realizada posteriormente pelo operador *Split*, simplificando a representação genética e garantindo o cumprimento das restrições de capacidade.

Escolha dos parâmetros

Nos algoritmos CSP foi utilizada a heurística *Minimum Remaining Values* (MRV), uma vez que tende a reduzir o fator de ramificação ao selecionar primeiro as

variáveis mais restritivas. Foram ainda implementados os mecanismos *Forward Checking* e *AC-3* para avaliar o impacto de diferentes níveis de propagação de restrições.

No algoritmo genético aplicado às N-Rainhas e ao CVRP foi utilizada seleção por torneio devido à sua simplicidade e eficácia na manutenção da pressão seletiva. O operador *Order Crossover* foi escolhido por preservar a validade das permutações, enquanto os operadores de mutação por troca e inversão introduzem diversidade sem destruir completamente a estrutura das soluções.

No PSO foram utilizados parâmetros que promovem um equilíbrio entre exploração e intensificação, enquanto no ACO foram analisadas diferentes combinações dos parâmetros (\beta) e (\rho), responsáveis pela influência da informação heurística e pela taxa de evaporação das feromonas. Esta análise permitiu identificar as configurações mais adequadas para as instâncias consideradas.

Reprodutibilidade experimental

A reprodutibilidade foi tratada como um requisito fundamental do projeto. Todas as experiências foram executadas com uma semente pseudoaleatória fixa ((RANDOM_SEED = 42)), sendo as sementes efetivamente utilizadas registadas para posterior verificação.

Os algoritmos foram implementados na biblioteca utils_algoritmos.py, enquanto a geração das experiências foi automatizada através do script reproduce_results.py. Os resultados produzidos foram armazenados em ficheiros CSV e utilizados na construção das tabelas e figuras apresentadas neste relatório. Esta organização garante que todas as experiências podem ser reproduzidas integralmente e que os resultados obtidos são verificáveis.

Apresentação e análise dos resultados experimentais

Este capítulo apresenta os resultados obtidos para os três problemas estudados, analisando o desempenho dos diferentes algoritmos implementados. As experiências foram executadas de forma reprodutível através do script reproduce_results.py, utilizando uma semente aleatória fixa e registando os resultados em ficheiros CSV posteriormente processados pelo notebook.

A avaliação foi efetuada recorrendo a métricas adequadas a cada problema. No problema das N-Rainhas foram analisados o tempo de execução, o esforço de procura, o número final de conflitos e a taxa de sucesso. No Problema do Caixeiro Viajante foi considerado o custo das rotas produzidas, complementado pela análise da estabilidade entre execuções e da influência dos parâmetros dos algoritmos. No Problema de Veículos com Capacidade foram avaliados o custo

total das soluções, o número de veículos utilizados, a existência de violações das restrições de capacidade e o tempo de execução.

Os resultados são apresentados e discutidos separadamente para cada problema, permitindo identificar as vantagens e limitações das diferentes abordagens implementadas.

Problema 1- N-Rainhas

Comparação global dos algoritmos

A comparação experimental foi realizada para as dimensões (N=8), (N=16), (N=32) e (N=64), utilizando dez execuções independentes por algoritmo. Foram analisadas quatro abordagens distintas: CSP com *Forward Checking* (CSP-FC), CSP com *AC-3* (CSP-AC3), Algoritmo Genético (GA) e *Tabu Search* (TS).

A Tabela 1 apresenta os resultados médios obtidos para cada algoritmo. Observa-se que as duas abordagens CSP e o *Tabu Search* alcançaram uma taxa de sucesso de 100% em todas as dimensões analisadas. O algoritmo genético apresentou um comportamento distinto, registando uma diminuição progressiva da taxa de sucesso à medida que o valor de (N) aumenta.

Tabela 1- Resultados médios obtidos para o problema das N-Rainhas.

	N	metodo	sucesso_pct	tempo_med	tempo_dp	esforco_med	conflitos_med
0	8	CSP-AC3	100.0000	0.0037	0.0002	10.0000	0.0000
1	8	CSP-FC	100.0000	0.0006	0.0001	52.0000	0.0000
2	8	GA	100.0000	0.0039	0.0023	1.8000	0.0000
3	8	Tabu	100.0000	0.0060	0.0063	20.6000	0.0000
4	16	CSP-AC3	100.0000	0.0184	0.0020	17.0000	0.0000
5	16	CSP-FC	100.0000	0.0007	0.0001	37.0000	0.0000
6	16	GA	80.0000	2.4331	4.0074	531.8000	0.2000
7	16	Tabu	100.0000	0.0447	0.0269	23.3000	0.0000
8	32	CSP-AC3	100.0000	0.4778	0.2632	38.0000	0.0000
9	32	CSP-FC	100.0000	0.0037	0.0013	78.0000	0.0000
10	32	GA	60.0000	5.2322	2.8522	688.8000	0.4000
11	32	Tabu	100.0000	0.8409	0.3692	34.0000	0.0000
12	64	CSP-AC3	100.0000	17.2818	0.8032	248.0000	0.0000
13	64	CSP-FC	100.0000	0.0650	0.0120	1240.0000	0.0000
14	64	GA	50.0000	8.4465	3.8502	1042.1000	0.5000
15	64	Tabu	100.0000	5.3806	1.5068	49.5000	0.0000

Em termos de tempo de execução, o *Forward Checking* revelou-se a abordagem mais eficiente, mantendo tempos inferiores a um décimo de segundo mesmo para a maior instância estudada. O *AC-3* apresentou tempos superiores devido

ao custo adicional da propagação de restrições, embora tenha explorado menos nós da árvore de procura. O *Tabu Search* manteve uma elevada robustez, mas à custa de tempos de execução significativamente superiores.

A Figura 1 sintetiza estes resultados através da evolução da taxa de sucesso, do tempo de execução e do esforço de procura para os diferentes algoritmos.

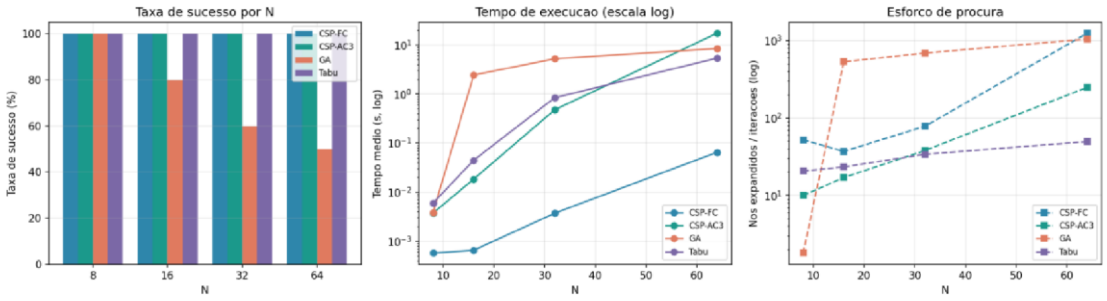


Figura 1- Comparação dos algoritmos aplicados ao problema das N-Rainhas.

Análise de escalabilidade

A tabela 1 evidencia diferenças claras entre os paradigmas analisados. Os métodos CSP mantêm uma taxa de sucesso de 100% em todas as dimensões testadas, demonstrando uma excelente capacidade de escalabilidade. O *Forward Checking* destaca-se ainda pelos reduzidos tempos de execução, resolvendo mesmo a instância de maior dimensão em poucas dezenas de milissegundos.

O *AC-3* apresenta igualmente uma taxa de sucesso de 100%, explorando menos nós do que o *Forward Checking*. No entanto, o custo adicional da propagação de restrições traduz-se em tempos de execução superiores, tornando-se visível uma troca entre redução do esforço de procura e custo computacional por operação.

O *Tabu Search* confirma a robustez observada no Projeto 1, mantendo sempre soluções válidas independentemente da dimensão do problema. Contudo, o número de iterações e o tempo necessário para atingir essas soluções são significativamente superiores aos observados nas abordagens CSP.

O algoritmo genético é o método mais afetado pelo crescimento do espaço de procura. Embora apresente um desempenho competitivo para instâncias pequenas, a taxa de sucesso diminui progressivamente à medida que o valor de (N) aumenta. Este comportamento indica que a representação por permutação, apesar de eliminar conflitos de linha e coluna, não é suficiente para garantir uma exploração eficaz das combinações diagonais em instâncias de maior dimensão.

Análise estatística

Para avaliar a relevância das diferenças observadas entre as abordagens mais eficazes, foi aplicado o teste não paramétrico de Wilcoxon aos tempos de execução do *Forward Checking* e do *Tabu Search* para a instância (N=64).

O teste produziu um valor (W=0,0) e um valor-p inferior ao nível de significância de 5%, permitindo rejeitar a hipótese nula de igualdade de desempenho. Assim, as diferenças observadas não podem ser atribuídas ao acaso e indicam uma vantagem estatisticamente significativa do *Forward Checking* em termos de eficiência computacional.

Apesar de ambos os algoritmos atingirem uma taxa de sucesso de 100%, o CSP com *Forward Checking* obtém as soluções em tempos substancialmente inferiores, evidenciando o benefício da exploração explícita das restrições do problema.

Discussão dos resultados

Os resultados obtidos mostram que a estrutura do problema desempenha um papel determinante no desempenho dos algoritmos. As abordagens CSP exploram diretamente as restrições que definem o problema, eliminando antecipadamente um grande número de configurações inviáveis. Esta capacidade de poda explica simultaneamente a elevada taxa de sucesso e os reduzidos tempos de execução observados experimentalmente.

A comparação entre *Forward Checking* e *AC-3* evidencia ainda um compromisso clássico entre propagação e custo computacional. Embora o *AC-3* reduza o número de nós explorados, o processamento adicional necessário para manter a consistência dos arcos acaba por aumentar o tempo total de execução. Para as dimensões analisadas, o *Forward Checking* revelou-se a solução mais equilibrada.

O *Tabu Search* confirmou os resultados obtidos no Projeto 1, demonstrando uma elevada robustez e capacidade para encontrar soluções válidas em todas as instâncias testadas. Contudo, a ausência de mecanismos explícitos de propagação obriga a uma exploração mais prolongada do espaço de procura, justificando os tempos de execução superiores aos das abordagens CSP.

Por sua vez, o algoritmo genético apresentou limitações crescentes à medida que a dimensão do problema aumentou. Apesar de a representação por permutação eliminar automaticamente conflitos de linha e coluna, a otimização dos conflitos diagonais torna-se progressivamente mais difícil em instâncias de maior dimensão. Como consequência, a população tende a convergir para soluções próximas do ótimo, mas nem sempre consegue eliminar todos os conflitos dentro do número de gerações considerado.

De forma global, os resultados indicam que os métodos de satisfação de restrições constituem a abordagem mais eficaz para o problema das N-Rainhas. A possibilidade de explorar explicitamente a estrutura do problema revelou-se mais vantajosa do que as abordagens genéricas de otimização, tanto em termos de eficiência como de escalabilidade.

Problema 2- TSP

Comparação entre PSO e ACO

A comparação experimental entre o *Particle Swarm Optimization* (PSO) e o *Ant Colony Optimization* (ACO) foi realizada em instâncias com 20, 50 e 100 cidades. Para cada dimensão foram efetuadas cinco execuções independentes, registando-se o custo da melhor rota encontrada e o respetivo tempo de execução.

A Figura 2 apresenta a evolução do melhor custo ao longo das iterações para uma instância representativa. Observa-se que ambos os algoritmos conseguem melhorar progressivamente as soluções iniciais, mas com comportamentos distintos. O *ACO* encontra rapidamente soluções de elevada qualidade, estabilizando próximo de um custo de 342 unidades. O *PSO* apresenta uma evolução mais gradual e converge para uma solução significativamente menos eficiente, com um custo próximo de 515 unidades.

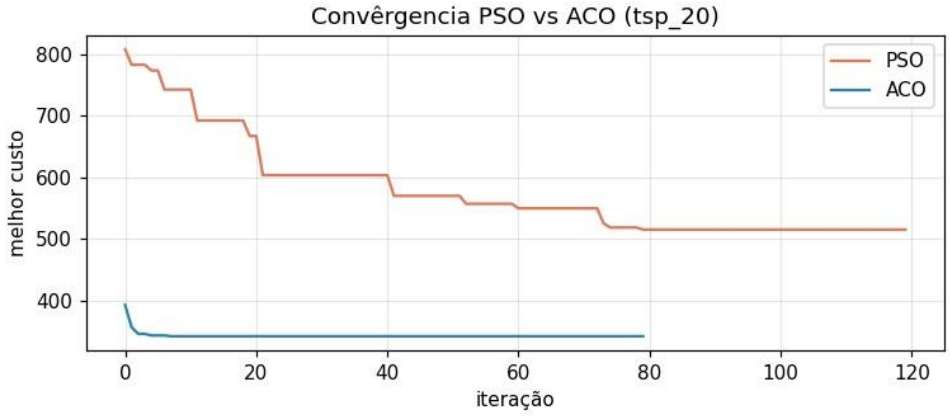


Figura 2- Curvas de convergência do PSO e do ACO para a instância TSP com 20 cidades.

Esta diferença resulta dos mecanismos de procura utilizados por cada algoritmo. Enquanto o *PSO* depende essencialmente da interação entre as melhores soluções individuais e globais do enxame, o *ACO* beneficia simultaneamente da informação heurística baseada na distância e do reforço progressivo das melhores rotas através das feromonas. Como consequência, o *ACO* consegue identificar mais rapidamente regiões promissoras do espaço de procura e produzir soluções de melhor qualidade.

Os resultados observados nesta primeira comparação sugerem uma vantagem clara do *ACO*, tanto em velocidade de convergência como na qualidade final das soluções obtidas.

Qualidade das soluções obtidas

A Figura 3 apresenta os custos médios obtidos pelos dois algoritmos para as três dimensões analisadas, bem como a variabilidade observada entre execuções.

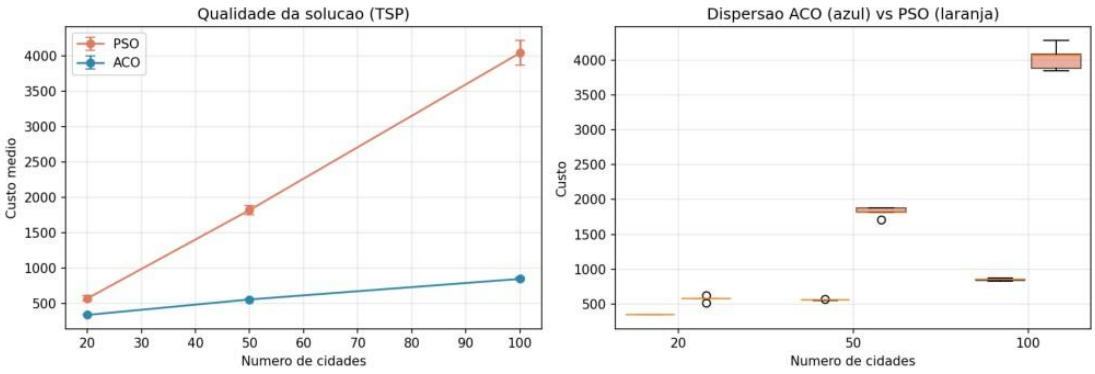


Figura 3- Comparação da qualidade das soluções obtidas pelo PSO e pelo ACO para diferentes dimensões do Problema do Caixeiro Viajante.

Os resultados mostram que o *ACO* supera consistentemente o *PSO* em todas as instâncias consideradas. Para 20 cidades, ambos os algoritmos obtêm soluções de qualidade relativamente próxima, embora o *ACO* já apresente uma vantagem visível. À medida que o número de cidades aumenta, essa diferença torna-se progressivamente mais acentuada. Para 50 e 100 cidades, os custos produzidos pelo *ACO* são significativamente inferiores aos obtidos pelo *PSO*, evidenciando uma melhor capacidade de escalabilidade.

Os diagramas de caixa mostram ainda que o *ACO* apresenta uma menor dispersão dos resultados entre execuções. As caixas mais estreitas e a reduzida amplitude dos valores observados indicam uma maior estabilidade e previsibilidade do algoritmo. Em contraste, o *PSO* revela uma variabilidade superior, particularmente para as instâncias de maior dimensão, sugerindo uma maior sensibilidade às condições iniciais e ao comportamento estocástico do processo de procura.

De forma global, os resultados confirmam que a vantagem observada na análise da convergência não se limita a uma execução isolada, mas mantém-se de forma consistente ao longo das diferentes instâncias e repetições realizadas.

Influência dos parâmetros

Para analisar a sensibilidade dos algoritmos aos parâmetros de configuração, foi realizado um estudo adicional sobre a instância com 50 cidades. No caso do *ACO*, foram testadas diferentes combinações dos parâmetros (\beta), responsável pela importância da informação heurística, e (\rho), associado à taxa de evaporação das feromonas.

A Figura 4 apresenta o mapa de calor dos resultados obtidos. Verifica-se que as melhores soluções surgem para valores elevados de (\beta) e valores reduzidos de (\rho). A melhor configuração observada corresponde a (\beta = 5,0) e (\rho = 0,1), produzindo um custo aproximado de 553 unidades. Estes resultados sugerem que uma forte valorização da distância entre cidades, combinada com uma evaporação lenta das feromonas, favorece a identificação e reforço de rotas de elevada qualidade.

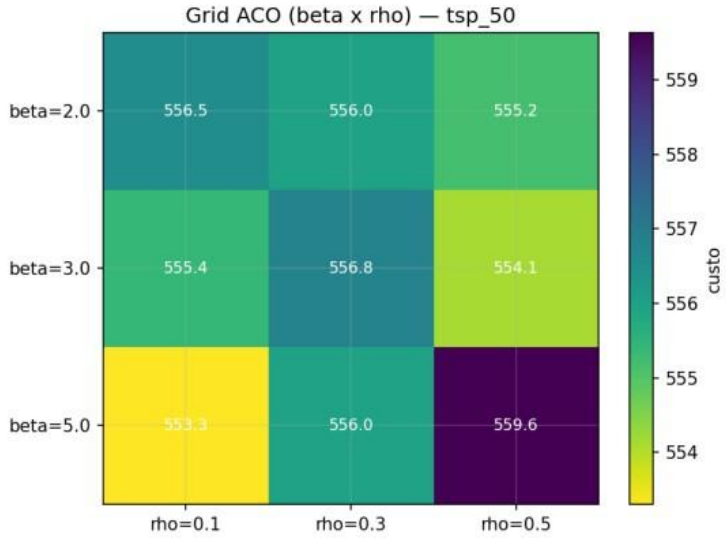


Figura 4- Análise da influência dos parâmetros β e ρ no desempenho do algoritmo ACO para a instância TSP com 50 cidades.

No caso do *PSO*, a melhor configuração foi obtida para (w = 0,5), (c_1 = 0,4) e (c_2 = 0,9). O valor elevado da componente social indica que o algoritmo beneficia de uma forte influência da melhor solução global encontrada pelo enxame. Apesar desta otimização dos parâmetros, os resultados obtidos permaneceram significativamente inferiores aos alcançados pelo *ACO*.

A análise realizada demonstra que a escolha dos parâmetros influencia diretamente a qualidade das soluções produzidas. No entanto, mesmo nas configurações mais favoráveis, o *ACO* manteve uma vantagem clara relativamente ao *PSO* para as instâncias consideradas.

Análise estatística

Para avaliar se as diferenças observadas entre os dois algoritmos são estatisticamente significativas, foi aplicado o teste não paramétrico de Wilcoxon aos custos obtidos nas diferentes execuções realizadas.

O teste produziu um valor (W=0,0) e um valor-p de 6,104 x 10**-5, muito inferior ao nível de significância de 5%. Estes resultados permitem rejeitar a hipótese nula de igualdade de desempenho entre os algoritmos.

Adicionalmente, o *ACO* obteve soluções de menor custo em todas as comparações realizadas, confirmando que a vantagem observada nos gráficos anteriores não resulta de flutuações aleatórias. Assim, pode concluir-se que o *ACO* apresenta um desempenho significativamente superior ao *PSO* para as instâncias do Problema do Caixeiro Viajante consideradas neste estudo.

Discussão dos resultados

Os resultados obtidos mostram que o *Ant Colony Optimization* é claramente mais adequado ao Problema do Caixeiro Viajante do que o *Particle Swarm*

Optimization na forma como foi implementado neste trabalho. A diferença tornase particularmente evidente à medida que o número de cidades aumenta, indicando uma melhor capacidade de escalabilidade do *ACO*.

Uma das razões para esta superioridade reside na utilização simultânea de informação heurística e aprendizagem coletiva. Desde o início da execução, as formigas são orientadas para cidades próximas através da visibilidade baseada na distância, enquanto o mecanismo de feromonas reforça progressivamente as melhores rotas encontradas. Esta combinação permite concentrar a procura em regiões promissoras do espaço de soluções sem eliminar totalmente a capacidade de exploração.

O *PSO*, por sua vez, revelou maiores dificuldades na adaptação ao domínio das permutações. Embora a representação por sequências de trocas permita preservar a validade das rotas, a ausência de uma componente heurística explícita reduz a capacidade do algoritmo para identificar rapidamente boas estruturas de percurso. Como consequência, a convergência ocorre para soluções de qualidade inferior e com maior variabilidade entre execuções.

Os resultados obtidos demonstram ainda a importância da parametrização dos algoritmos. No caso do *ACO*, verificou-se que uma forte valorização da informação heurística e uma evaporação lenta das feromonas favorecem a obtenção de soluções de melhor qualidade. No entanto, mesmo considerando as melhores configurações encontradas para ambos os algoritmos, a vantagem do *ACO* manteve-se consistente.

De forma global, os resultados indicam que a presença de informação heurística explorável constitui um fator decisivo neste problema, permitindo ao *ACO* alcançar níveis de desempenho superiores aos observados no *PSO*.

Problema 3- CVRP

Qualidade das soluções obtidas

O desempenho do algoritmo genético foi avaliado em instâncias com 50 e 100 clientes, analisando-se o custo total das rotas, o número de veículos utilizados e o cumprimento das restrições de capacidade.

Os resultados obtidos mostram que o algoritmo foi capaz de gerar soluções viáveis de forma consistente em todas as execuções realizadas. Em nenhum dos casos foram observadas violações das restrições de capacidade, o que evidencia a eficácia da estratégia *Giant-Tour + Split* na construção de rotas compatíveis com os limites impostos aos veículos. Esta característica é particularmente importante no contexto do CVRP, uma vez que garante que as soluções produzidas são diretamente aplicáveis sem necessidade de procedimentos adicionais de reparação.

À medida que o número de clientes aumenta, observa-se um crescimento previsível do custo total das soluções e do número de veículos necessários. Para

a instância com 50 clientes, o algoritmo obteve custos médios próximos de 1185 unidades utilizando aproximadamente 6 veículos. Para 100 clientes, o custo médio aumentou para cerca de 2922 unidades, sendo necessários aproximadamente 12 veículos para satisfazer toda a procura.

Os desvios-padrão observados são relativamente reduzidos quando comparados com os valores médios, indicando uma boa estabilidade entre execuções e uma reduzida sensibilidade à componente aleatória do algoritmo.

Análise das rotas geradas

A Figura 5 apresenta um exemplo de solução obtida para a instância com 50 clientes. O depósito encontra-se representado no centro do mapa, enquanto as diferentes rotas são identificadas através de cores distintas.

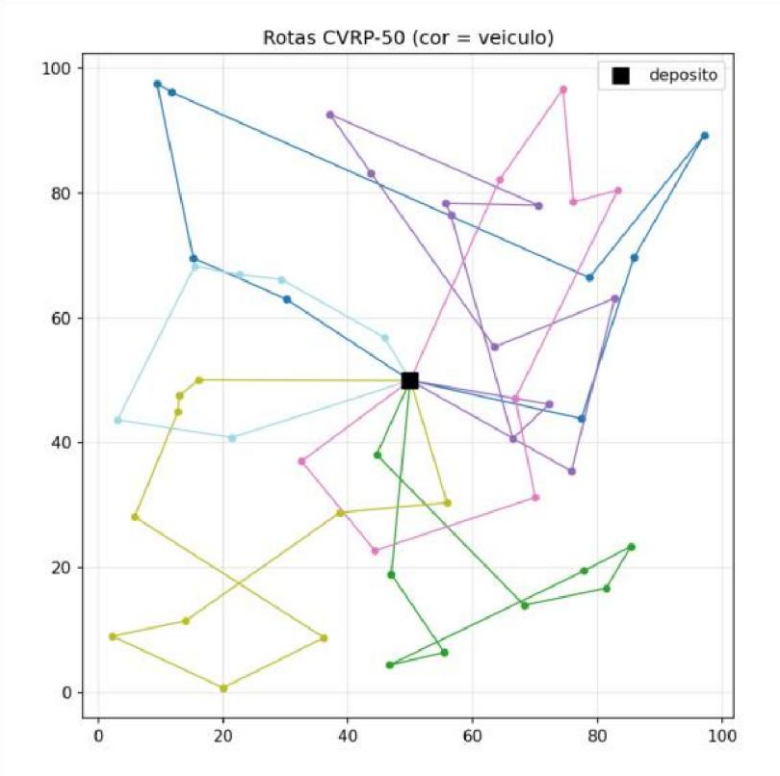


Figura 5- Exemplo de solução obtida para a instância CVRP com 50 clientes.

Observa-se que os clientes tendem a ser agrupados em regiões geograficamente próximas, reduzindo deslocações desnecessárias entre zonas afastadas. Esta organização espacial contribui para a redução do custo total e evidencia a capacidade do algoritmo para construir rotas coerentes do ponto de vista logístico.

A solução ilustrada apresenta um custo total de aproximadamente 1193 unidades e utiliza exatamente 6 veículos, valor que coincide com o limite inferior teórico calculado a partir da procura total e da capacidade disponível. A inexistência de violações confirma ainda que o procedimento *Split* cumpre eficazmente o seu objetivo de garantir a viabilidade das rotas geradas.

Discussão dos resultados

Os resultados obtidos demonstram que a combinação entre algoritmo genético e estratégia *Giant-Tour + Split* constitui uma abordagem eficaz para o Problema de Veículos com Capacidade. A representação utilizada permite separar a tarefa de ordenar os clientes da tarefa de construir rotas viáveis, simplificando significativamente o processo de otimização.

A ausência total de violações de capacidade em todas as execuções confirma a robustez do procedimento de divisão das rotas. Além disso, o número de veículos utilizado manteve-se muito próximo do mínimo teoricamente necessário, evidenciando uma utilização eficiente dos recursos disponíveis.

O aumento do custo total e do número de veículos com o crescimento do número de clientes corresponde ao comportamento esperado para este tipo de problema. Apesar do aumento da complexidade, o algoritmo manteve uma boa estabilidade entre execuções, produzindo soluções de qualidade semelhante para a mesma instância.

De forma global, os resultados indicam que os algoritmos genéticos constituem uma ferramenta flexível e eficaz para problemas de roteamento com restrições. Ao contrário do observado no problema das N-Rainhas, onde a estrutura das restrições favoreceu claramente as abordagens CSP, o CVRP revelou-se um domínio onde a representação genética especializada consegue explorar eficientemente o espaço de soluções e produzir resultados de elevada qualidade.

Comparação entre o Projeto 1 e o Projeto 2

Os dois projetos desenvolvidos ao longo da unidade curricular permitiram explorar um conjunto diversificado de paradigmas de procura e otimização, aplicados a problemas com características distintas. No Projeto 1 foram estudados algoritmos de procura em espaço de estados e procura local, enquanto no Projeto 2 o foco incidiu sobre técnicas de satisfação de restrições, algoritmos genéticos e metaheurísticas inspiradas em sistemas naturais.

O problema das N-Rainhas assumiu um papel particularmente relevante por ter sido abordado nos dois projetos. Esta continuidade permitiu comparar diretamente métodos de procura local, como o *Tabu Search*, com abordagens baseadas em satisfação de restrições e otimização evolucionária. Os resultados mostraram que a exploração explícita da estrutura do problema através de propagação de restrições conduz a ganhos significativos de eficiência, enquanto as abordagens mais genéricas tendem a necessitar de um esforço de procura superior.

O Projeto 2 permitiu ainda alargar o estudo a problemas de roteamento e distribuição, introduzindo desafios distintos dos observados no Projeto 1. Nestes domínios, a utilização de informação heurística e mecanismos de aprendizagem coletiva revelou-se particularmente eficaz, como demonstrado pelo desempenho

do *Ant Colony Optimization*. Por outro lado, os algoritmos genéticos evidenciaram uma elevada flexibilidade, adaptando-se a problemas com restrições complexas através de representações especializadas.

Em conjunto, os dois projetos demonstram que a escolha de um algoritmo não deve ser feita de forma isolada, mas sim em função da estrutura do problema e da informação disponível para orientar a procura. A principal conclusão é que diferentes paradigmas apresentam vantagens em contextos distintos, não existindo uma abordagem universalmente superior para todos os problemas de procura e otimização.

Discussão crítica dos resultados

Os resultados obtidos ao longo deste trabalho evidenciam que o desempenho de um algoritmo depende fortemente da forma como este consegue explorar a estrutura do problema que pretende resolver. Embora todos os métodos estudados tenham sido capazes de produzir soluções válidas em pelo menos parte das instâncias analisadas, observaram-se diferenças significativas em termos de eficiência, qualidade das soluções e capacidade de escalabilidade.

A comparação realizada permitiu identificar padrões consistentes entre os diferentes problemas estudados. Nos casos em que existe uma estrutura explícita de restrições, como no problema das N-Rainhas, os algoritmos capazes de explorar diretamente essa informação revelaram uma vantagem clara. Em contrapartida, em problemas de otimização combinatória onde a estrutura é menos facilmente explorável, as metaheurísticas e os algoritmos evolucionários mostraram-se alternativas competitivas.

Influência da estrutura do problema

A principal conclusão retirada deste trabalho é que a estrutura do problema constitui um fator determinante na escolha da abordagem de resolução. O problema das N-Rainhas possui restrições explícitas e facilmente modeláveis, permitindo que os algoritmos CSP utilizem mecanismos de propagação para eliminar antecipadamente um grande número de configurações inviáveis. Esta capacidade reduz drasticamente o espaço de procura e explica o excelente desempenho observado para o *Forward Checking* e para o *AC-3*.

Em contraste, o algoritmo genético aplicado ao mesmo problema não dispõe de informação explícita sobre as restrições. Apesar da representação por permutação eliminar automaticamente alguns conflitos, a procura continua a ser orientada apenas pela função de aptidão, tornando mais difícil identificar soluções ótimas à medida que a dimensão do problema aumenta.

Nos problemas de roteamento, a situação é diferente. Embora existam restrições e objetivos bem definidos, a estrutura não é tão facilmente explorável através de propagação. Nestes casos, métodos baseados em exploração estocástica e aprendizagem coletiva revelam-se mais adequados, como demonstrado pelo

desempenho do *Ant Colony Optimization* no TSP e pelo algoritmo genético utilizado no CVRP.

Comparação entre paradigmas

A comparação entre paradigmas permitiu identificar vantagens e limitações específicas de cada abordagem.

Os métodos de satisfação de restrições destacaram-se pela sua eficiência e capacidade de escalabilidade quando existe uma estrutura explícita que pode ser explorada através de propagação e poda. O seu principal ponto forte reside na redução sistemática do espaço de procura antes mesmo da exploração efetiva das soluções.

As metaheurísticas inspiradas em sistemas naturais mostraram-se particularmente adequadas para problemas de otimização combinatória. O *Ant Colony Optimization* beneficiou da combinação entre informação heurística e aprendizagem coletiva, conseguindo produzir soluções de elevada qualidade de forma consistente. O *Particle Swarm Optimization*, embora funcional, revelou maiores dificuldades na adaptação ao espaço discreto das permutações.

Os algoritmos genéticos apresentaram um comportamento mais dependente do problema considerado. No domínio das N-Rainhas, a ausência de mecanismos específicos para explorar as restrições limitou a sua eficácia. Já no CVRP, a utilização de uma representação especializada e do procedimento *Split* permitiu obter soluções viáveis e competitivas. Estes resultados demonstram que o sucesso dos algoritmos genéticos depende fortemente da qualidade da representação e dos operadores utilizados.

Limitações do estudo

Apesar dos resultados obtidos, o estudo apresenta algumas limitações que devem ser consideradas na interpretação das conclusões.

Em primeiro lugar, as experiências foram realizadas sobre instâncias sintéticas de dimensão moderada. Embora estas permitam comparar os algoritmos de forma controlada e reprodutível, não representam toda a diversidade de situações encontradas em problemas reais.

Em segundo lugar, o número de repetições utilizado foi suficiente para uma análise comparativa, mas poderia ser aumentado para obter estimativas estatísticas ainda mais robustas. Da mesma forma, o conjunto de parâmetros explorado, especialmente no caso do PSO e do ACO, foi necessariamente limitado por restrições de tempo computacional.

Por último, o estudo incidiu sobre algoritmos puros, não tendo sido exploradas abordagens híbridas que combinem as vantagens de diferentes paradigmas.

Possíveis melhorias e trabalho futuro

Existem várias direções promissoras para aprofundar o trabalho desenvolvido.

No problema das N-Rainhas, seria interessante combinar algoritmos genéticos com mecanismos de procura local, criando algoritmos meméticos capazes de corrigir conflitos através de procedimentos de melhoria local. Poderia também ser explorada a utilização de heurísticas adicionais nos algoritmos CSP, como a ordenação de valores por menor restrição.

No Problema do Caixeiro Viajante, uma extensão natural consistiria na integração de operadores de melhoria local, como o 2-opt, frequentemente utilizados para refinar as rotas produzidas por metaheurísticas. A análise de instâncias de maior dimensão permitiria igualmente avaliar com maior rigor a escalabilidade das abordagens estudadas.

Relativamente ao CVRP, seria interessante incorporar custos fixos associados à utilização dos veículos e considerar variantes mais realistas do problema, incluindo janelas temporais, múltiplos depósitos ou frotas heterogéneas.

De forma mais geral, uma linha de trabalho particularmente relevante consiste no desenvolvimento de abordagens híbridas que combinem a capacidade de exploração das metaheurísticas com mecanismos de propagação, reparação ou melhoria local especializados. Os resultados obtidos neste projeto sugerem que a combinação de paradigmas poderá constituir uma estratégia mais eficaz do que a utilização isolada de qualquer método.

Conclusões

O presente trabalho permitiu estudar e comparar diferentes paradigmas de procura e otimização através da sua aplicação a três problemas clássicos da Inteligência Artificial e da otimização combinatória. A implementação integral dos algoritmos proporcionou uma compreensão aprofundada dos seus mecanismos de funcionamento e permitiu avaliar experimentalmente o seu desempenho em condições controladas e reprodutíveis.

No problema das N-Rainhas, os resultados demonstraram que os métodos de satisfação de restrições são particularmente eficazes quando existe uma estrutura explícita que pode ser explorada através de mecanismos de propagação. As abordagens baseadas em *Forward Checking* e *AC-3* obtiveram elevadas taxas de sucesso e tempos de execução reduzidos, superando claramente as abordagens evolucionárias. O *Tabu Search* confirmou a robustez já observada no Projeto 1, embora com um custo computacional superior ao dos métodos CSP.

No Problema do Caixeiro Viajante, o *Ant Colony Optimization* revelou-se consistentemente superior ao *Particle Swarm Optimization*, produzindo soluções de melhor qualidade e menor variabilidade entre execuções. Os resultados

mostraram que a combinação entre informação heurística e aprendizagem coletiva constitui uma vantagem significativa neste tipo de problemas, permitindo uma exploração mais eficiente do espaço de procura.

Relativamente ao Problema de Veículos com Capacidade, o algoritmo genético baseado na estratégia *Giant-Tour + Split* demonstrou ser uma abordagem eficaz para a construção de soluções viáveis e de boa qualidade. A ausência de violações das restrições de capacidade e a utilização de um número de veículos próximo do mínimo teórico evidenciam a adequação da representação escolhida ao problema em estudo.

De forma global, os resultados confirmam que não existe um algoritmo universalmente superior para todos os problemas de procura e otimização. O desempenho observado depende fortemente da natureza do problema, da informação disponível e da capacidade de cada abordagem para explorar a estrutura existente. Os métodos de satisfação de restrições destacam-se quando as restrições podem ser explicitamente modeladas e propagadas, as metaheurísticas revelam vantagens em problemas de otimização complexos com informação heurística relevante, e os algoritmos genéticos demonstram uma elevada flexibilidade quando apoiados por representações adequadas ao domínio.

Em síntese, o trabalho permitiu consolidar os conhecimentos adquiridos na unidade curricular e demonstrar, através de evidência experimental, a importância de adequar o paradigma de resolução às características específicas de cada problema.

Referências Bibliográficas

[1] Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4.ª ed.). Pearson.

[2] Dorigo, M., & Stützle, T. (2004). *Ant Colony Optimization*. MIT Press.

[3] Kennedy, J., & Eberhart, R. (1995). Particle Swarm Optimization. *Proceedings of the IEEE International Conference on Neural Networks*, 1942– 1948.

[4] Clerc, M. (2004). Discrete Particle Swarm Optimization, Illustrated by the Traveling Salesman Problem. In *New Optimization Techniques in Engineering* (pp. 219–239). Springer.

[5] Holland, J. H. (1992). *Adaptation in Natural and Artificial Systems*. MIT Press.

[6] Mackworth, A. K. (1977). Consistency in Networks of Relations. *Artificial Intelligence*, 8(1), 99–118.

[7] Glover, F. (1989). Tabu Search — Part I. *ORSA Journal on Computing*, 1(3), 190–206.

[8] Dantzig, G. B., & Ramser, J. H. (1959). The Truck Dispatching Problem. *Management Science*, 6(1), 80–91.

[9] Prins, C. (2004). A Simple and Effective Evolutionary Algorithm for the Vehicle Routing Problem. *Computers & Operations Research*, 31(12), 1985–2002.